

4-Quadrant Benchmark - DETALHADO (% real por-check)

Date: 2026-05-27 | Models: google/gemma-3-4b-it, meta-llama/llama-3.2-3b-instruct, qwen/qwen-2.5-7b-instruct

Cases: 5 | max_iters: 3 | base: https://openrouter.ai/api/v1

Por que dois numeros?

O harness padrao reporta PASS BINARIO POR CASO: um caso so passa se TODOS os checks batem de uma vez - isso joga o Q1 (raw) pra 0% mesmo acertando parte do contrato. A % REAL POR-CHECK conta cada check individualmente (igual ao bench principal que mede 'a real %'). Use por-check pra ver progresso real; binario pra ver casos 100% prontos.

Headline - % real por-check vs binario por-caso

Quadrante	Prompt	Exec	% real (check)	checks	binario (caso)
Q1	raw	1-shot	33%	26/78	0/15 (0%)
Q2	simplicio	1-shot	89%	70/78	11/15 (73%)
Q3	raw	loop	76%	60/78	7/15 (46%)
Q4	simplicio	loop	91%	71/78	11/15 (73%)

Prompt effect (% real): Q2 - Q1 = +56 pts (33% -> 89% por-check). Ate o 'raw 1-shot' (Q1) acerta 33% dos checks - nao e 0%; o 0% era o all-or-nothing por caso.

% real por-check, por modelo

Model	Q1	Q2	Q3	Q4
google/gemma-3-4b-it	34%	96%	65%	96%
meta-llama/llama-3.2-3b-instruct	26%	73%	65%	76%
qwen/qwen-2.5-7b-instruct	38%	100%	100%	100%

Por tipo de check (todos modelos x casos)

Ordem dos 5 checks: target-file, DIFF-block, TEST-block, role-keyword, structural-guard.

Check	Q1	Q2	Q3	Q4
1 target file	0%	100%	80%	100%
2 DIFF block	0%	100%	73%	93%
3 TEST block	0%	80%	66%	80%
4 role keyword	93%	86%	93%	93%
5 structural guard	73%	80%	73%	86%

Leitura

- % real por-check: Q1 33% -> Q2 89% (+56 pts so com o prompt). Q4 91% e o teto.
 - O salto vem dos checks ESTRUTURAIS (DIFF/TEST/target) que o contrato exige no [OUTPUT]; os semanticos (role, guard) o modelo ja acerta mesmo no raw.
 - qwen-2.5-7b satura 100% por-check em Q2/Q3/Q4; ganho do loop concentra em gemma/llama.
- Fonte: bench/results_4quadrant.json (run 2026-05-27, OpenRouter).