

simplicio bench v13 — INTERIM (5 sides, batch em andamento)

Captura: 2026-05-30 21:46:45

Snapshot parseado dos logs ao vivo. Modelos com headline (Llama-3B) já fecharam; Gemma-4B em andamento; Qwen-Coder-32B ainda nem começou. Vou regenerar o PDF final quando os 3 modelos × 2 benches × 5 lados fecharem.

Sides

sem = baseline (raw goal) · **com** = cli alone (6-layer) · **sp** = cli + sp (composition) · **ag** = cli + ag (verify-loop max 3) · **spag** = cli + sp + ag (composition + retry)

Headline — modelos fechados

Model	Metric	base	cli	cli+sp	cli+ag	cli+sp+ag	Δcli	Δsp	Δag	Δsp+ag
llama-3.2-3b-instruct	exec	8%	8%	8%	8%	8%	+0	+0	+0	+0
llama-3.2-3b-instruct	regex	32%	69%	67%	88%	76%	+37	+35	+56	+44

Em andamento (parcial)

Model	Bench	Cases done / total	Tally so far
gemma-3-4b-it	exec	6/12	base=1 cli=5 sp=4 ag=5 spag=3
gemma-3-4b-it	regex	5/10	base=8/26 cli=25/26 sp=24/26 ag=25/26 spag=24/26