

simplicio bench v13 — INTERIM (5 sides, batch em andamento)

Captura: 2026-05-30 22:10:41

Snapshot parseado dos logs ao vivo. Modelos com headline (Llama-3B) já fecharam; Gemma-4B em andamento; Qwen-Coder-32B ainda nem começou. Vou regenerar o PDF final quando os 3 modelos × 2 benches × 5 lados fecharem.

Sides

sem = baseline (raw goal) · **com** = cli alone (6-layer) · **sp** = cli + sp (composition) · **ag** = cli + ag (verify-loop max 3) · **spag** = cli + sp + ag (composition + retry)

Headline — modelos fechados

Model	Metric	base	cli	cli+sp	cli+ag	cli+sp+ag	Δcli	Δsp	Δag	Δsp+ag
llama-3.2-3b-instruct	exec	8%	8%	8%	8%	8%	+0	+0	+0	+0
llama-3.2-3b-instruct	regex	32%	69%	67%	88%	76%	+37	+35	+56	+44
gemma-3-4b-it	exec	33%	66%	50%	66%	41%	+33	+17	+33	+8
gemma-3-4b-it	regex	42%	92%	88%	92%	92%	+50	+46	+50	+50
qwen-2.5-coder-32b-instruct	exec	8%	16%	16%	16%	16%	+8	+8	+8	+8
qwen-2.5-coder-32b-instruct	regex	34%	44%	38%	82%	80%	+10	+4	+48	+46

Em andamento (parcial)

nenhum modelo em andamento