

v14 INTERIM — bench funcional (PHPUnit, 3 models × 12 cases × 5 sides)

Snapshot: 2026-05-31 00:38:42

Bench rodando em background. Modelos com headline (-> baseline...) fecharam; sem headline = ainda rodando. PHPUnit como oracle, schema v1 ativo em todos os lados sp.

Configuração

Model	Backend	Tiers sp
deepseek/deepseek-v4-flash	OpenRouter API	64 → 100
local:Qwen/Qwen2.5-Coder-3B-Instruct	transformers CPU fp32	4 (single)
local:Qwen/Qwen2.5-Coder-1.5B-Instruct	transformers CPU fp32	4 (single)

deepseek -v4 -flash

STATUS: EM ANDAMENTO (6/12 cases)

Parcial: base 2/6 · cli 6/6 · cli+sp 6/6 · cli+ag 6/6 · cli+sp+ag 6/6

Case	b	c	cli+sp	u	modal	parse	ag	sp+ag
password_strength	.	P	P	62	2	59/64	P(1)	P(1)
password_require_symbol	P	P	P	60	3	57/64	P(1)	P(1)
env_get_int	.	P	P	57	3	59/64	P(1)	P(1)
env_get_bool	.	P	P	55	4	55/64	P(1)	P(1)
admin_only_allowed_roles	P	P	P	39	8	61/64	P(1)	P(1)
rate_limit_bucket_key	.	P	P	30	18	58/64	P(1)	P(1)

Achados notáveis

- DeepSeek V4 Flash honra schema v1 em média 91% dos N=64 subagents (349 parse_ok de 384 totais)
- cli+sp passou em 6/6 cases processados — TODOS pararam cycle 1, sem escalar pra N=100
- cli+ag passou em 6/6 cases processados, todos em 1 attempt (nenhum retry necessário)

Quando o batch terminar (DeepSeek faltam ~6 cases, depois Qwen 3B + 1.5B em CPU = várias horas), gera relatório final com PDF.