

v14 INTERIM — bench funcional (PHPUnit, 3 models × 12 cases × 5 sides)

Snapshot: 2026-05-31 01:56:07

Bench rodando em background. Modelos com headline (-> baseline...) fecharam; sem headline = ainda rodando. PHPUnit como oracle, schema v1 ativo em todos os lados sp.

Configuração

Model	Backend	Tiers sp
deepseek/deepseek-v4-flash	OpenRouter API	64 → 100
local:Qwen/Qwen2.5-Coder-3B-Instruct	transformers CPU fp32	4 (single)
local:Qwen/Qwen2.5-Coder-1.5B-Instruct	transformers CPU fp32	4 (single)

deepseek -v4 -flash

STATUS: FECHADO (12/12 cases)

Side	Passed	Rate	Δ vs baseline
baseline	6/12	50%	—
cli	11/12	91%	+41
cli+sp	9/12	75%	+25
cli+ag	12/12	100%	+50
cli+sp+ag	12/12	100%	+50

Case	b	c	cli+sp	u	modal	parse	ag	sp+ag
password_strength	.	P	P	62	2	59/64	P(1)	P(1)
password_require_symbol	P	P	P	60	3	57/64	P(1)	P(1)
env_get_int	.	P	P	57	3	59/64	P(1)	P(1)
env_get_bool	.	P	P	55	4	55/64	P(1)	P(1)
admin_only_allowed_roles	P	P	P	39	8	61/64	P(1)	P(1)
rate_limit_bucket_key	.	P	P	30	18	58/64	P(1)	P(1)
base_repository_build_where_sql	P	P	P	73	9	82/100	P(1)	P(1)
router_has	P	P	.	—	—	—	P(1)	P(1)
bugfix_password_policy_lowercase		P	.	—	—	—	P(1)	P(1)
password_assess	P	P	P	62	3	56/64	P(1)	P(1)
base_repository_build_update_sql	.	P		59	4	52/64	P(1)	P(1)
router_extract_params	P	P	.	—	—	—	P(1)	P(1)

local:Qwen/Qwen2.5-Coder-3B-Instruct

STATUS: EM ANDAMENTO (0/12 cases)

Achados notáveis

- DeepSeek V4 Flash honra schema v1 em média 81% dos N=64 subagents (552 parse_ok de 712 totais)

- cli+sp passou em **9/12 cases** processados — TODOS pararam cycle 1, sem escalar pra N=100
- cli+ag passou em **12/12 cases** processados, todos em 1 attempt (nenhum retry necessário)

Quando o batch terminar (DeepSeek faltam ~6 cases, depois Qwen 3B + 1.5B em CPU = várias horas), gera relatório final com PDF.